

ANÁLISE DE DADOS EM PLATAFORMA DE VÍDEOS COM PYSPARK (BIG DATA)

1. INTRODUÇÃO E DESCRIÇÃO DO PROBLEMA

Plataformas de streaming e vídeo geram grandes volumes de dados continuamente, incluindo informações sobre usuários, conteúdos e interações.

Nesse contexto, surgem desafios como:

- Processar grandes volumes de dados de forma eficiente;
- Identificar padrões de consumo de conteúdo;
- Extrair insights relevantes para retenção de usuários.

Ferramentas tradicionais tornam-se limitadas nesse cenário, sendo necessário o uso de tecnologias de processamento distribuído.

Dessa forma, o PySpark surge como solução para análise de dados em larga escala, permitindo manipulação eficiente e escalável dessas informações.

2. JUSTIFICATIVA E USO DE DADOS

O uso do PySpark neste projeto permite trabalhar com grandes volumes de dados de forma distribuída, aumentando a eficiência no processamento.

A análise foi direcionada para:

- Identificar padrões de consumo de conteúdo;
- Avaliar métricas de engajamento;
- Analisar distribuição de dados entre diferentes categorias;
- Preparar dados para análises mais avançadas.

O PySpark permite dividir os dados em múltiplas partições e processá-los em paralelo, aumentando a performance e escalabilidade

3. COLETA DE DADOS

Os dados utilizados representam uma base de uma plataforma de vídeos.

Características dos dados:

- Tipo: estruturados (CSV);
- Origem: arquivos carregados no ambiente (Google Colab / Spark);
- Conteúdo: informações sobre vídeos, métricas e possíveis interações;
- Volume: adequado para simular processamento distribuído.

Os arquivos foram carregados no ambiente Spark para processamento utilizando DataFrames.

4. MODELAGEM E TRATAMENTO DOS DADOS

A preparação dos dados foi realizada utilizando PySpark DataFrames.

Principais etapas:

- Leitura de arquivos CSV no ambiente Spark;
- Inferência e ajuste de tipos de dados;;
- Seleção e transformação de colunas relevantes;
- Tratamento de valores inconsistentes ou nulos;
- Aplicação de transformações (select, filter, groupBy).

Além disso, foram aplicados conceitos fundamentais do Spark:

- Transformações (lazy evaluation);
- Ações (execução efetiva).

Essas etapas garantiram eficiência no processamento e qualidade dos dados analisados.

5. ANÁLISE EXPLORATÓRIA DE DADOS (EDA)

A análise exploratória foi conduzida utilizando operações distribuídas.

Principais análises:

Agregações:

- Contagem de registros;
- Agrupamento por categorias;
- Ordenação por métricas relevantes.

Distribuição de dados:

- Identificação de conteúdos mais frequentes;
- Análise de concentração de dados por categoria.

Processamento distribuído:

- Uso de groupBy e aggregations em larga escala;
- Execução otimizada via Spark.

Essa abordagem permitiu explorar grandes volumes de dados de forma eficiente.

6. PRINCIPAIS INSIGHTS

A análise revelou padrões importantes no comportamento da plataforma:

- Existe concentração de conteúdos em determinadas categorias, indicando preferência do público;
- A distribuição desigual dos dados sugere que poucos conteúdos concentram grande parte da relevância (efeito “long tail”);
- A agregação de dados evidenciou diferenças significativas entre categorias, indicando oportunidades de segmentação;
- O volume de dados reforça a necessidade de processamento distribuído para análises eficientes;
- A estrutura dos dados permite evolução para análises mais avançadas, como recomendação de conteúdo.

7. RESULTADOS

O projeto demonstrou a aplicação prática do PySpark na manipulação e análise de dados em larga escala.

Principais resultados:

- Processamento eficiente de dados utilizando DataFrames distribuídos;
- Aplicação de transformações e agregações em ambiente escalável;
- Estruturação de dados para análises futuras.

Além disso, o projeto evidenciou:

- Ganho de performance em comparação com processamento tradicional;
- Capacidade de lidar com grandes volumes de dados;
- Base para construção de pipelines de dados.

8. SUGESTÕES DE AÇÃO

Com base nos insights obtidos, recomenda-se:

- Utilizar análises para identificar conteúdos mais consumidos e direcionar estratégias de produção;
- Implementar sistemas de recomendação com base em padrões identificados;
- Monitorar distribuição de conteúdo para equilibrar o catálogo;
- Evoluir o pipeline para ingestão contínua de dados.

9. CONCLUSÃO

O projeto demonstrou como o uso do PySpark permite analisar dados em larga escala de forma eficiente e estruturada.

A utilização de processamento distribuído possibilitou trabalhar com volumes maiores de dados, aplicando transformações e extraindo insights relevantes.

Dessa forma, o projeto reforça a importância de tecnologias de Big Data na análise moderna, especialmente em contextos como plataformas digitais e streaming.